

RAPPORT DU PROJET DE COMPILATION

08-JAN-2019

Développement d'un compilateur en C++

Réalisé par:
BOUCHANE Amine
CHAMI Rachid
EL AOUAD Ilyas
EL MOHAMMADI Sohaib

Encadré par: Monsieur SOUHAIL EL GHAZI

Contents

	0.1	Introduction
1	Par	tie léxicale 9
	1.1	Grammaire initiale
	1.2	Grammaire améliorée
	1.3	L'alphabet du langage
	1.4	Exemple de programme
	1.5	Tables léxicale
	1.6	Automate du langage
		1.6.1 Erreurs
	1.7	Structures de données utilisées
		1.7.1 Enumération des mots du langage
		1.7.2 Structures de données
		1.7.3 Fonction de Hashage
	1.8	Exemple d'éxécution du lexicale
		1.8.1 Affichage erreurs
2	Par	tie Syntaxique 27
	2.1	Grammaire améliorée
	2.2	Enlever la récursivité à gauche et factoriser la grammaire 29
	2.3	Table des Premiers et Suivants pour cette grammaire
	2.4	Résolution des ambiguitées
	2.5	Améliorations
		2.5.1 Les operations d'affectation
		2.5.2 Les parametres d'une fonction
		2.5.3 Le problème de Programme et Liste instructions
		2.5.4 Problème déclaration et instruction
		2.5.5 Manipulation des chaines
	2.6	La grammaire finale
	2.7	Exemples d'erreurs levées par le syntaxique:
		1 V 1

Développement d'un compilateur en C++

3	Par	Partie Sémantique 4			
	3.1	Introd	$\operatorname{luction} \ldots \ldots \ldots \ldots \ldots \ldots \ldots \ldots$	45	
	3.2	La gra	ammaire du langage avec des actions sémantiques	46	
	3.3	Défini	tion des actions sémantiques	47	
		3.3.1	Vérification des redéfinitions	47	
		3.3.2	Vérification des définitions	47	
		3.3.3	Vérification du caractère simple ou composé d'une variable	48	
		3.3.4	Vérification des types	48	
		3.3.5	Vérifications des index nulles	48	
		3.3.6	Vérification des manipulations de chaines	49	
	3.4	Struct	tures utilisées	50	
		3.4.1	Table des symboles	50	
		3.4.2	La structure variable	50	
	3.5	Exem	ples d'erreurs levées par le sémantique	51	

List of Figures

1.1	Alphabet du langage	11
1.2	Table des unités lexicales	13
1.3	Table des unités lexicales	14
1.4	Automate du langage	15
1.5	Automate du langage	16
1.6	Automate du langage	17
1.7	Automate du langage	18
1.8	Automate du langage	19
1.9	Automate du langage	20
1.10	input du léxical	24
1.11		25
1.12	Erreur : Introduction d'un mot qui n'appartient pas au langage	26
1.13	Erreur : Chaine de caractères qui ne finit pas par "	26
0.4		20
2.1	or a contract of the second of	29
2.2	0	30
2.3	O	31
2.4	9	32
2.5		33
2.6	1 0	34
2.7		42
2.8	Erreur : oublie du point virgule	42
2.9		42
2.10	Erreur : oublie de fermer un crochet ouvrant	42
		43
2.12	Erreur: opération non permise	43
2.13	Texte source	43
2.14	Erreur : oublie de donner un type lors de la déclaration d'une fonction.	43
2.15	Texte source	43
2.16	Erreur : oublie de l'identifiant	43

3.1	Grammaire avec actions sémantiques	46
3.2	Grammaire avec actions sémantiques	46
3.3	Erreur index négative.	48
3.4	Erreur index négative.	49
3.5	Erreur de redéfinition.	51
3.6	Erreur de redéfinition.	51
3.7	Erreur des types lors d'une affectation	51
3.8	Erreur des types lors d'une affectation	52
3.9	Erreur des types lors d'une affectation	52
3.10	Erreur des types lors d'une affectation	52
3.11	Erreur des types lors d'une affectation	52
3.12	Erreur des types lors d'une affectation	52
3.13	Erreur d'indice d'un tableau	52
3.14	Erreur d'indice d'un tableau	52
3.15	Erreur de définition.	52
3.16	Erreur de définition	52

0.1 Introduction

Ce document a pour but décrire le déroulement du projet proposé par M. EL GHAZI au cours du module Théorie de la Compilation. C'est le résultat du travail qui nous a permis d'implémenter un compilateur depuis le langage C— et lui proposer un analyseur léxical, syntaxique et finalement sémantique.

Chapter 1

Partie léxicale

1.1 Grammaire initiale

```
< liste -declarations> < liste -fonctions>
<liste-declarations> : <liste-declarations> < declarations> | epsilon
<declarations> : int <liste-declarateurs>
<liste-declarateurs> : <list-declarateurs> , <declarateur>
    | <declarateur>
<Declarateur> : identificateur | identificateur [ constante ]
<liste-fonctions> : <liste-fonctions> <fonction> | epsilon
<forction> : <type> identificateur ( <liste-parms> )
        { < liste -declarations > < liste -instructions > }
        | extern <type> identificateur ( <liste-parms> );
<type> : void | int
<liste-parms> : <liste-parms> , <parm> | epsilon
<parm> : int identificateur
<liste-instructions> : <liste-instructions> <instruction> | epsilon
<instruction> : <iteration> | <selection> | <saut>
    | <affectation >; | <bloc> <appel>
<iteration> : for (<affectation> ; <condition>
        ; <affectation >) <instruction >
          while (<condition>) <instruction>
        | if (<condition>) <instruction>
        if ( <condition > ) <instruction > else <instruction >
<saut> : return ; | return <expression> ;
<affectation>: <variable> = <expression>
<bloc> : { <liste-instructions> }
```

1.2 Grammaire améliorée

```
<liste-declarations> : <liste-declarations> < declarations> | epsilon
<declarations> : int <liste-declarateurs>
    | chaine < liste - declarateurs >
<liste-declarateurs> : <list-declarateurs> , <declarateur>
    | <declarateur>
<Declarateur> : identificateur | identificateur [ constante ]
<liste-fonctions> : <liste-fonctions> <fonction> | epsilon
<forction> : <type> identificateur ( <liste-parms> )
        { < liste -declarations > < liste -instructions > }
        | extern <type> identificateur ( <liste-parms> );
<type> : void | int | chaine
<liste-parms> : <liste-parms> , <parm> | epsilon
<parm> : int identificateur
<liste-instructions> : <liste-instructions> <instruction> | epsilon
<instruction> : <iteration> | <selection>
    | <saut> | <affectation >; | <bloc> <appel>
<iteration> : for (<affectation> ; <condition>
        ; <affectation >) <instruction >
        | while (<condition>) <instruction>
        if ( <condition > ) < instruction >
```

```
| if ( <condition > ) <instruction > else <instruction >
<saut> : return ; | return <expression> ;
<affectation>: <variable> = <expression>
<bloc>: { <liste-instructions> }
<appel> : identificateur (<liste-expressions>);
<variable> : identificateur | identificateur [ <expression> ]
<expression> : ( <expression> )
         | <expression > <binary-op> <expression >
         | - \langle expression \rangle
         | <variable>
         | identificateur ( <liste-expressions> )
<liste-expressions> : <liste-expressions> , <expression> | epsilon
<condition> : ! ( <condition> )
         | <condition> <binary-rel> <condition>
         | ( < condition > ) |
         | <expression > <binary -comp> <expression >
<binary-op> : + | - | * | / | << | >> | & | ||
<br/>
<br/>
dinary-rel> : && | ||
<binary-comp> : < | >= | <= | == | !=</pre>
<lire> : lire (<liste-declarateur>);
<ecrire> : ecrire (<liste-declarateur>);
<chaine> : "<DefChaine>"
<DefChaine> : <lettre> <DefChaine>
    | <chiffre > < DefChaine > | epsilon
<entier> : <chiffre ≫entier>|epsilon
< mot > : < letter > < mot > | epsilon
< chiffre > : 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9
<lettre> : a |\dots| z |A| \dots |Z|
```

1.3 L'alphabet du langage

II. L'alphabet du langage :

```
\Sigma = \{ 0...9, ; , , , {\parallel , \parallel } , = , \parallel !, < , > , & , + , - , * , / , (,), [ , ] , a . . . z , A . . . Z , | , & }
```

Figure 1.1: Alphabet du langage

1.4 Exemple de programme

```
chaine maChaine1;
                     /* Variable globale de type chaine */
chaine maChaine2;
Int MaPremiereFonction (int a , int b ) {
        int resultat;
        resultat = a + b;
        return resultat;
}
void MaDeuxiemeFonction( int nombre ){
        int i;
        for (i=0; i \le nombre; i=i+1)
                 ecrire(i);
int MaTroisemeFonction(int a, int b){
        if (a>b)
                 return a;
        else
                return b;
int main() {
        int a, b;
        ercire ("donnez le premier nombre");
        lire(a);
        ercire ("donnez le deuxieme nombre");
        lire(b);
if(MaTroisiemeFonction(a,b) == a)
        ecrire (maChine1);
else
        ecrire (maChaine2);
return 0;
}
```

1.5 Tables léxicale

Unité Iexicale	Lexème	Attribut	Model
PLUS	+		+
MOINS	-		-
MULT	*		*
DIV	/		1
INF	<		<
SUP	>		>
	&		&
BARRE			
NON	!		!
AFF	=		=
SOMICOLO N	;		;
INFEG	<=		<=
SUOEG	>=		>=
EGAL	==		==
DIFF	!=		!=
ET	&&		&&
OU	II		
DINF	<<		<<
DSUF	>>		>>
PAROUV	((
PARFER))
ACCOUV	{		{
ACCFER	}		}
CROCHOUV	[[
CROCHFER]]

Figure 1.2: Table des unités lexicales

CROCHFER]]
PAROUV	((
PARFER))
INT	1,27	Valeur de l'entier	Chiffre+
TAB	Tab[9]	l'indice dans la table des symboles	IDENT[Chiffre+]
CHAINE	"Bonjour ", "bon7jo ur "	Position dans la table des chaines de caractères	" (lettre chiffre)* "
IDENT	IDENT A1	Positon dans la table des identificate urs	Lettre(lettre chiffre)*
MOTCLE	extern,int,void,chai ne	Position dans la table des mots clés	lettre+

Figure 1.3: Table des unités lexicales

1.6 Automate du langage

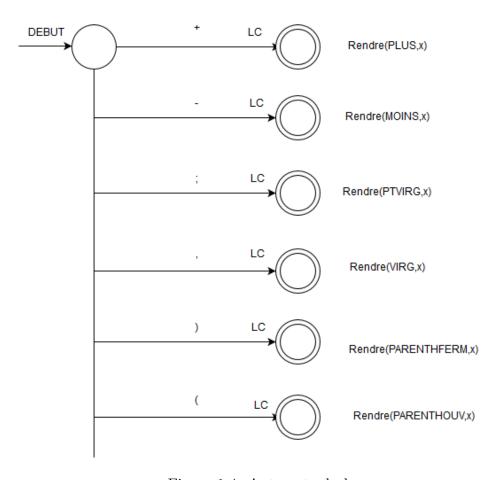


Figure 1.4: Automate du langage

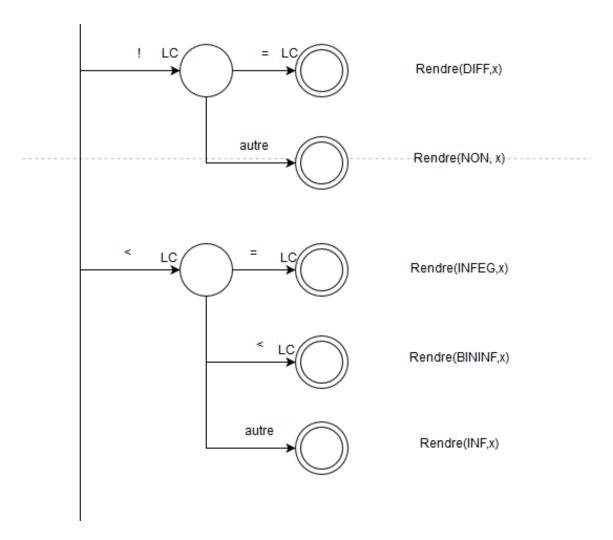


Figure 1.5: Automate du langage

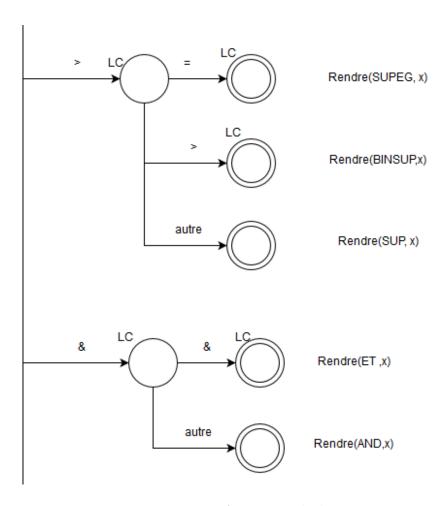


Figure 1.6: Automate du langage

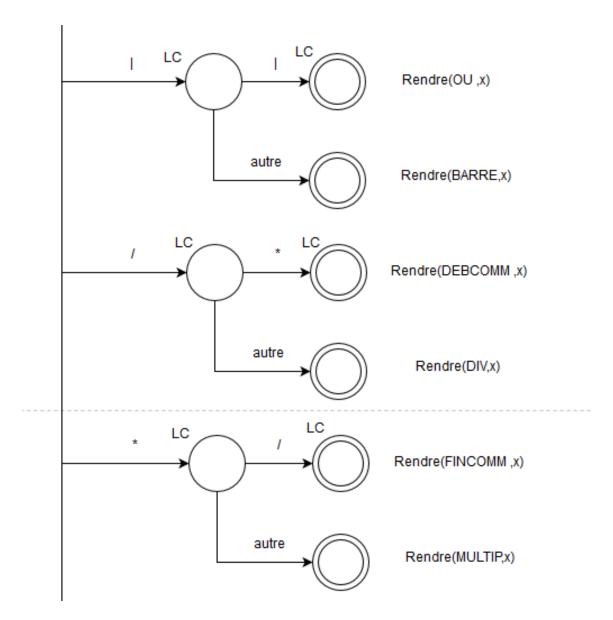


Figure 1.7: Automate du langage

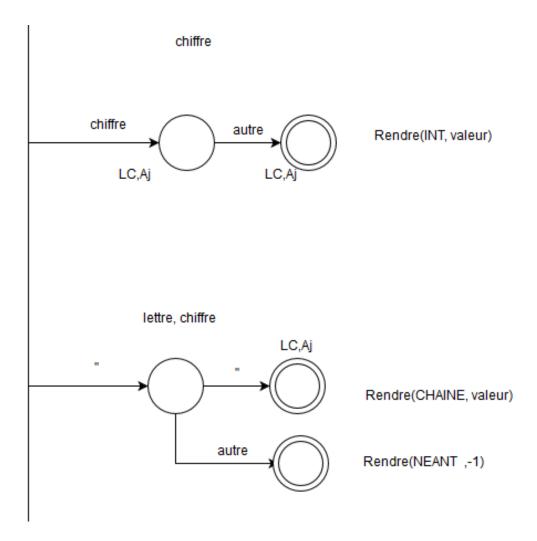


Figure 1.8: Automate du langage

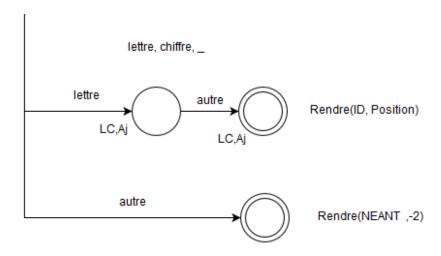


Figure 1.9: Automate du langage

1.6.1 Erreurs

Le lexical est concu pour lever deux erreurs :

- $\bullet\,$ Lexeme non appartenant au langage;
- Chaine non terminée.

Les autres erreurs seront traitées dans la partie syntaxique et sémantique.

1.7 Structures de données utilisées

1.7.1 Enumération des mots du langage

C'est l'énumération des unités lexicales utilisée pour distinguer entre les mots du langages et les identifiants etc.

1.7.2 Structures de données

Unitée

On utilise cette structure pour stocker les léxèmes rencontrés lors de la lecture; et pouvoir les récuperer au moment convenable. On utilise un élément ul de Mots pour montrer sur quel lexeme on travail et un pair (entier; entier) nommé attribut pour stocker la position:

- d'une chaine de caractères: le premier entier c'est son hash (position dans la table des chaines) et le deuxième c'est son indexe dans la liste chainée en cas de collision.
- un identifiant ou le premier entrer c'est son hash (position dans la table des identifiants) et le deuxième c'est son index dans la liste chainée en cas de collision.

- un chiffre : ou le premier entier c'est sa valeur; le deuxième c'est, par convention, -1
- un mot clé : premier entier et le deuxième, par convention, égale à -1

Chaine

```
struct chaine {
    std::string valeur;
    chaine* suivant;
};
```

On utilise cette structure pour stocker les chaines de caractères sous forme de liste chainée (utilisable dans le cas des collisions). Elle contient, un string qui contient sa valeur; et le suivant qui pointe sur l'élément suivant de la liste chainée.

Identifiant

```
struct identif {
        std::string identifiant;
        identif* suivant;
    };
```

C'est la struct des identifiants, Similaire à celle des chaines.

Tableaux de données

```
std::vector<identif*> tableauIdentif = std::vector<identif*> (100, nullptr
std::vector<chaine*> Chaines = std::vector<chaine*> (100, nullptr);
```

Le choix des vecteurs dynamiques est fait dans le but de mieux gérer la mémoire.

Map des mots Clés

```
std::map<std::string, Mots> motCles; // Map des mots cles
```

décider si un lexeme est mot clé ou non. La map utilisée prend comme indice un string et contient l'unité lexicale correspondante au mot clé; Par exemple : mot-Cles("if") va retourner la position de 'if' dans l'énumérations. Et motCles('goto') va retourner zéro, donc ce n'est pas un mot clé. Ps : L'énumération des mots du langage contient un ZERO au début pour différencier entre l'éxistence d'un mot clé ounon.

Unité suivante

```
unite unite_uniteSuivante();
```

Fonction qui retourne la structure de l'unité dans laquelle on se trouve.

1.7.3 Fonction de Hashage

La fonction de hashage utilisée suit le schéma suivant:

- transforme le mot en miniscule; pour ne pas avoir des différences entre un identifiant en majuscule et autre en miniscule;
- parcours tous ces caracters et multiplie par un nonce (nombre qui s'incrémente à chaque itération);
- retourne un nombre ; 100 (taille du tableau des identifiants).

Le code de la fonction:

```
int AnalyseLexical::hash(string str) {
   int nonce = 1;
   int hash = 0;
   str = stringToLower(str);
   for(std::string::iterator it=str.begin(); it!=str.end(); ++it){
        hash += ((int)*it ) * nonce;
        ++nonce;
   }
   return hash % 100;
} // Fin hash(string)
```

1.8 Exemple d'éxécution du lexicale

Entrée

Figure 1.10: input du léxical

Sortie

```
==> Analyse lexicale :
(Lexeme : int
                      Attribut : -1
                                             unite lexicale : 1)
(Lexeme : a1
                      Attribut : 95
                                             unite lexicale : 3)
(Lexeme : ;
                      Attribut : -1
                                             unite lexicale: 33)
(Lexeme : int
                      Attribut : -1
                                             unite lexicale : 1)
                      Attribut : 97
                                             unite lexicale : 3)
(Lexeme : a2
                      Attribut : -1
                                             unite lexicale : 33)
(Lexeme : ;
                                             unite lexicale : 1)
(Lexeme : int
                      Attribut : -1
                      Attribut : 99
                                             unite lexicale : 3)
(Lexeme : a3
                      Attribut : -1
                                             unite lexicale : 15)
(Lexeme : [
(Lexeme : 22
                      Attribut : -1
                                             unite lexicale : 12)
(Lexeme : ]
                      Attribut : -1
                                             unite lexicale: 16)
                      Attribut : -1
                                            unite lexicale : 33)
(Lexeme : extern
                             Attribut : -1
                                                    unite lexicale : 5)
                                             unite lexicale : 1)
                      Attribut : -1
(Lexeme : int
(Lexeme : produit
                             Attribut : 0 unite lexicale : 3)
```

Figure 1.11: Output du léxical

1.8.1 Affichage erreurs

```
(Lexeme : [
                      Attribut : -1
                                             unite lexicale : 15)
(Lexeme : 23
                     Attribut : -1
                                             unite lexicale : 12)
(Lexeme : ]
                      Attribut : -1
                                             unite lexicale : 16)
                      Attribut : -1
                                             unite lexicale : 33)
(Lexeme : ;
(Lexeme : erreur d'alphabet
                             Attribut : -1
                                                            unite lexicale : 45)
=> Probleme dans la partie lexicale.
```

Figure 1.12: Erreur : Introduction d'un mot qui n'appartient pas au langage

```
(Lexeme : [
                      Attribut : -1
                                              unite lexicale : 15)
Lexeme : 3
                      Attribut : -1
                                              unite lexicale : 12)
                      Attribut : -1
(Lexeme : ]
                                             unite lexicale : 16)
Lexeme : =
                      Attribut : -1
                                            unite lexicale : 40)
Lexeme : erreur chaine non complete
                                             Attribut : -1
                                                                     unite lexicale : 46)
Erreur Chaine non complete, " non trouve. Ligne : 28
```

Figure 1.13: Erreur : Chaine de caractères qui ne finit pas par "

Chapter 2

Partie Syntaxique

2.1 Grammaire améliorée

```
< liste -declarations> < liste -fonctions>
<liste-declarations> : <liste-declarations> < declarations> | epsilon
<declarations> : int <liste-declarateurs>
    | chaine < liste -declarateurs >
<liste-declarateurs> : <list-declarateurs> , <declarateur>
    | <declarateur>
<Declarateur> : identificateur | identificateur [ constante ]
<liste-fonctions> : <liste-fonctions> <fonction> | epsilon
<forction> : <type> identificateur ( <liste-parms> )
        { < liste -declarations > < liste -instructions > }
        extern <type> identificateur ( te-parms> );
<type> : void | int | chaine
<liste-parms> : <liste-parms> , <parm> | epsilon
<parm> : int identificateur
<liste-instructions> : <liste-instructions> <instruction> | epsilon
<instruction> : <iteration> | <selection>
    | <saut> | <affectation >; | <bloc> <appel>
<iteration> : for (<affectation> ; <condition>
        ; <affectation >) <instruction >
        | while (<condition>) <instruction>
        if ( <condition > ) < instruction >
        if ( <condition > ) <instruction > else <instruction >
<saut> : return ; | return <expression> ;
```

```
<affectation> : <variable> = <expression>
<bloc> : { <liste-instructions> }
<appel> : identificateur (<liste-expressions>);
<variable> : identificateur | identificateur [ <expression> ]
<expression> : ( <expression> )
         | <expression > <binary-op> <expression >
          - <expression>
          <variable>
         | identificateur ( te-expressions > )
<liste-expressions> : <liste-expressions> , <expression> | epsilon
<condition> : ! ( <condition> )
         | <condition > <binary-rel > <condition >
         | ( < condition > ) |
         | <expression > <binary -comp> <expression >
<binary-op> : + | - | * | / | << | >> | & | | |
<br/><br/>dinary-rel> : && | ||
<binary-comp> : < | > | >= | <= | == | !=</pre>
<lire> : lire (<liste-declarateur>);
<ecrire> : ecrire (<liste-declarateur>);
<chaine> : "<DefChaine>"
<DefChaine> : <lettre> <DefChaine>
    | <chiffre > < DefChaine > | epsilon
<entier> : <chiffre ≫entier>|epsilon
< mot > : < letter > < mot > | epsilon
< chiffre > : 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9
<lettre> : a |\dots| z |A| \dots |Z|
```

2.2 Enlever la récursivité à gauche et factoriser la grammaire

```
2- 2- declarations> : liste-declarations> <declarations> | epsilon
2- 2- declaration> : <delcaration> liste-declaration> | epsilon
3- <declarations> : int int iste-declarateurs>; | chaine liste-declarateurs>;
4- 4- declarateurs> ; declarateur> | <declarateur> |
             Recursivite a gauche:
4-1 < liste-declarateurs> : < declarateur> < liste-declarateurs'>
4-2 < liste-declarateurs'> : , < declarateur> < liste-declarateurs'> | epsilon
5- < Declarateur>: identificateur | identificateur [ constante ]
                         <Declarateur'> : [ constante ] | epsilon
             Donc:
5-1 < Declarateur> : identificateuur < Declarateur'>
5-2 < Declarateur'> : [ constante ] | epsilon
6- 6- fonctions> : liste-fonctions> <fonction> | epsilon
             Recursivite a gauche :
             Donc:
6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6- 6-
7- <fonction> : <type> identificateur ( <parm> ste-parms> ) { ste-declarations> te-parms> 
instructions> }
                         | extern <type> identificateur ( <parm> te-parms> );
```

Figure 2.1: Enlever la récursiyité à gauche et factorisation

```
8- <type> : void | int | chaine
9- 9- ste-parms> : liste-parms> , <parm> | epsilon
       Donc:
9-1 < liste-parms> : <parm> < liste-parms> ' | epsilon
9-2 < liste-parms'> : , <parm> < liste-parms'> | epsilon
10- <parm> : int identificateur | chaine identificateur
11- liste-instructions> : liste-instructions> <instruction> | epsilon
       Donc
11 - liste-instructions> : <instruction> liste-instructions> | epsilon
12- <instruction> : <iteration> | <selection> | <saut> | <affectation>; | <bloc> | <appel>
13- <iteration> : for (<affectation> ; <condition> ; <affectation>) <instruction>
       | while (<condition>) <instruction>
14- <selection>: if ( <condition> ) < instruction>
       Donc
14-1 <selection> : if (condition) <instruction> <selection'>
14-2 <selection'> : else <instruction> | epsilon
15-<saut>: return ; | return <expression> ;
       Donc:
15-1 <saut> : <return> <saut'>
15-2 <saut'> : <expression> ; | ;
```

Figure 2.2: Enlever la récursivité à gauche et factorisation

```
16- <affectation> : <variable> = <expression>
17- <bloc> : { liste-instructions> }
18- <appel> : identificateur (<liste-expressions>);
19- <variable> : identificateur | identificateur [ <expression> ]
19-1 <variable> : identificateur <variable'>
19-2 <variable'> : [ <expression> ] | epsilon
20- <expression> : ( <expression> )
     -- | <expression> <binary-op> <expression>
     -- <expression>
     -| <variable>
      - | identificateur ( < liste-expressions> )
20-2 <expression'> : <binary-op> <expression> <expression'> | epsilon
20-1 <expression> : ( <expression> ) <expression'>
```

Figure 2.3: Enlever la récursivité à gauche et factorisation

```
20-1 <expression> : ( <expression>) <expression'>
                     | - <expression> <expression'>
                     | identificateur <expression">
20-2 <expression'> : <binary-op> <expression> <expression'> | epsilon
20-3 <expression"> : ( ( iste-expressions> ) <expression"> | <variable"> <expression">
21- liste-expressions> ; liste-expressions> , <expression> | epsilon
       Recursivite a gauche:
       Donc:
21- expression> < liste-expression> | epsilon
22- < condition> : ! ( < condition> )
| <condition> <binary-rel> <condition>
- ( < condition> )
      | <expression> <binary-comp> <expression>
       Donc:
22-1 <condition> : ! ( <condition> ) <condition'>
                     | ( <condition > ) <condition '>
                     | <expression > <binary-comp > <expression > <condition' >
22-2 <condition'> : <binary-rel> <condition> <condition'> | epsilon
23- <binary-op> : + | - | * | / | << | >> | & | ||
24- <binary-rel> : && | ||
```

Figure 2.4: Enlever la récursivité à gauche et factorisation

2.3 Table des Premiers et Suivants pour cette grammaire

Regle de Production	Premiers	Suivant	LL1
Programme	-	-	<u>oui</u>
Liste-declarations	{epsilon, int, chaine}	{int chaine, for, while, if,}	NON
Declarations	{int}, {chaine}	4	QUI
Liste-declarateurs	-	-	QUI
Liste-declarateurs'	{epsilon, ,}	{int, chaine}	QUI
Declarateur	-	-	QUI
Declarateur'	{[}	{int, chaine, ,}	QUI
Liste-fonctions	{epsilon, void, int ,chaine, extern}	{\$}	QUI
Fonction	{int, void, chaine}, {extern}	-	OM
Туре	{void}, {int}, {chaine}	-	QUI
Liste-parms	{epsilon, ,}	{)}	QUI
Parm	{int}, {chaine}	-	QUI
Liste-instructions	{for, while, if, return {, identificateur}	{}}	QUI
Instuction	{for}, {while}, {if}, {return}, {identificateur}, {{}}	-	OM
Iteration	{for}, {while}	-	<u>QUI</u>

Figure 2.5: Table des Premiers et Suivants pour cette grammaire

Iteration	{for}, {while}	-	QUI
Selection	-	-	QUI
Selection'	{epsilon, else}	{}}	QUI
Saut	-	-	QUI
Saut'	{;}, {(, - , identificateur}	-	OUI
Affectation	-	-	QUI
Bloc	-	-	QUI
Appel	-	-	QUI
Variable	-	-	QUI
Variable'	{epsilon,[}	{+ - * / << >> & , < > >= <= == !=, && }	OM
Expression	{(},{-},{identificateur}	-	QUI
Expression'	{epsilon, + ,- , *, / , << , >> , & , }	{],), ;, && , , + ,- , *, / , << , >> , & , }	NON
Expression"	{(}, {]}	-	QUI
Liste-expressions	{epsilon, ,}	{)}	QUI
Condition	{!},{ (},{ (,-, identificaeur}	-	NON
Condition'	{&& , , epsilon}	{&&, }	NON

Figure 2.6: Table des Premiers et Suivants pour cette grammaire

2.4 Résolution des ambiguitées

La première ambiguitée se trouve dans liste declarations où on constate que le premier et le suivant de ¡liste-declarations¿ sont d'intersectio non vide. Pour remédier à cela, on suivera une méthode d'éclatation des non terminaux pour trouver la partie commune et la factoriser.

On se retrouve avec la grammaire suivante :

```
1-1 chaine chai
```

```
| extern <type> identificateur (<liste-parms> );
      cprogramme>
                        epsilon
1-2 cprogramme'> : identificateur cprogramme''>
1-3 cprogramme''> : <declarateur'>
      <liste -declarateurs '>; cprogramme>
                        (te-parms>) { te-declarations>
<liste -instructions> }                                                                                                                                                                                                                                                                                                                                                 <
2- te-declaration> : <delcaration> <liste-declaration>
            epsilon
3- <declarations>: int <liste-declarateurs>;
            | chaine < liste - declarateurs > ;
4-1 < liste -declarateurs > : < declarateur > < liste -declarateurs '>
4-2 < liste-declarateurs'> : , < declarateur> < liste-declarateurs'>
            epsilon
5-1 < Declarateur > : identificateuur < Declarateur'>
5-2 < Declarateur'> : [ constante ] | epsilon
8- <type> : void | int | chaine
```

Maintenant, l'intersection qui était non vide est devenu vide, et "int, chaine" que faisaient problème sont réunies dans programme .

2.5 Améliorations

2.5.1 Les operations d'affectation

La grammaire tolere les operations de type "a=b+c", mais elle ne tolere pas "a="chaine";" ou bien "a=3" etc. On peut ajouter cette fonctionalite a travers les changements suivants :

Cela donnera à chaine les même manipulations d'un entrier. Si on veut restreindre le nombre d'opérations en un nombre précis, on peut créer une expression" similaire à expression' qui va contenir une liste d'opérations binaires bien choisis destinés à être utilisés avec les chaines. Pour notre projet, on choisit de donner toute liberté à manipuler les chaines et avoir la possibilité d'implémenter plusieurs fonctionnalités selon le besoin qui peuvent être utilisées avec les chaines sans avoir à implémenter une bibliothèque de gestion des chaines de caractères. Le but de ce projet et d'integrer les chaines de caractères complétement dans le langage et ne pas restreidre ces manipulations seulement à la concaténation, etc...

2.5.2 Les parametres d'une fonction

Si on enleve la recursivite a gauche à liste parametres, on se trouve avec :

```
<liste-parms> : , <parm> <liste-parms> | epsilon
```

Mais cela pose probleme lorsqu'il s'agit de mettre plusieurs paramtres ou aucun. On la transforme vers ceci:

```
9-1 < liste -parms > : <parm > < liste -parms '> | epsilon
9-2 < liste -parms '> : , <parm > < liste -parms '> | epsilon
```

Même problème avec liste-expressions et on la remplace par ce qui suit :

```
21-1 < liste-expressions > : < expression > < liste-expressions '> | epsilon  
21-2 < liste-expressions '> :, < expression > < liste-expressions '> | epsilon
```

2.5.3 Le problème de Programme et Liste instructions

Sur le code de Programme, on retourne 'true' pour representer le 'epsilon' sur la grammaire, ie, ne pas avoir d'autres definitions de fonctions ou declarations. Mais cela pose probleme si on ajoute une instruction a l'exterieur de la fonction, même s'il detecte que cela ne doit pas etre tolere, le 'else return true' final le montre comme juste. Pour remedier a cela, on va ajouter une condition que verifie s'il s'agit d'une operation non tolerable, elle retourne false;

```
// Programme
...
} else if (motCourant.ul == ERR) {
     //ERR c'est la fin du fichier ou erreur d'alphabet
    return true;
```

```
} else {
    return false;
}
```

Ce même probleme on le trouve avec liste-instructions dans son code. Pour le resoudre, on ajoute un flag "insideFalse" qui se leve si on trouve une faute a l'interieur d'une instruction.

2.5.4 Problème déclaration et instruction

```
bool AnalyseSyntaxique::declaration(){
   if (motCourant.ul == INT) {
     ...
   } else {
     return true;
}}
```

meme que cela retourne un false, liste-declarations retourne un true a cause du epsilon (else return true;). Pour remedier a ce probleme on va eclater declaration dans liste declarations et l'éliminer.

Meme chose avec jinstructionį. On va eclater jinstructionį dans įliste instrucitonsį et on va avoir:

```
12-1 < liste -instructions > : < iteration > < liste -instructions > | < selection > < liste -instructions > | < saut > < liste -instructions > | identificateur < aff -app >; < liste -instructions > | < bloc > < liste -instructions > | epsilon
```

2.5.5 Manipulation des chaines

Après avoir fait ces améliorations, on trouve que chaine peut être manipulée de la même facon qu'une constante, etc. Sur ce, on a le choix. Soit d'ajouter des opérations définies dans le langages que traites les chaines, soit les abolir.

Donc, on choisira de donner sens à ces opérations, tels que:

- + : Concatenation de deux chaines ou d'une chaine et un entier;
- - : suppression à partir de la fin de la chaine la partie commune et lever une erreur si on est face à un caractere non commun;
- == : Vérifier si deux chaines ont les mêmes caractères;
- != : L'opposé de ==
- \bullet j ou ξ ou ξ ou ξ ou ξ : raisonnent sur la somme du code ASCII des caractères.

Donc, on aura un langage riche qui supporte complétement le type chaine et on fera ces changements sur la grammaire :

Cette transformation va interdir les operations telles que "a = "aa" * "bb";" et "a = "aa" * 3;" mais va tolérer " a = 3 * "aa";"; Cette partie va être traitée dans la partie sémantique.

2.6 La grammaire finale

```
1−1 programme> : int cyramme
                    | chaine cprogramme'>
                     void identificateur (<liste-parms> ) {
     <liste -declarations > <liste -instructions > }   
                    extern <type> identificateur (<liste-parms>);
     cprogramme>
                    epsilon
1-2 cprogramme'> : identificateur cprogramme''>
1-3 cprogramme''> : <declarateur'> liste-declarateurs'>;
     cprogramme>
                    (te-parms>) { te-declarations>
     <liste -instructions> }                                                                                                                                                                                                                                                                                                                                                 <
2- 2- declaration > : int int declarateurs >;
     <liste-declaration>
          | chaine < liste -declarateurs >;
     <liste-declaration> | epsilon
3- <declarations> : int <liste-declarateurs> ;
          | chaine < liste - declarateurs > ;
4-1 < liste -declarateurs > : < declarateur > < liste -declarateurs '>
4-2 < liste-declarateurs' > : , < declarateur > < liste-declarateurs' >
          epsilon
5-1 < Declarateur > : identificateuur < Declarateur'>
5-2 < Declarateur'> : [ constante ] | epsilon
8- <type> : void | int | chaine
9-1 < liste-parms> : <parm> < liste-parms'> | epsilon
9-2 < liste-parms'> : , <parm> < liste-parms'> | epsilon
10- <parm> : int identificateur | chaine identificateur
12-1 < liste -instructions > : < iteration > < liste -instructions >
     | < selection > < liste -instructions >
     | < saut > < liste - instructions >
     | identificateur <aff-app>;<liste-instructions>
       <bloc><liste -instructions>
      epsilon
12-2 <aff-app>:<variable'>=<expression>
     | (< liste - expressions >) |
13- <iteration> : for (<affectation> ; <condition> ;
     <affectation >) <instruction >
```

```
| while (<condition>) <instruction>
14-1 < selection > : if (condition) < instruction > < selection'>
14-2 < selection '> : else < instruction > | epsilon
15-1 < \text{saut} > : < \text{return} > < \text{saut}' >
15-2 < \text{saut'} > : < \text{expression} > ; \mid ;
16- <affectation> : <variable> = <expression>
17- <bloc> : { liste-instructions> }
19-1 <variable> : identificateur <variable'>
19-2 <variable'> : [ <expression> ] | epsilon
20-1 <expression> : ( <expression>) <expression'>
                 | - <expression > <expression '>
                   identificateur <expression''>
                  <chaine> <expression '''>
                 constante <expression'>
20-2 <expression'> : <binary-op> <expression> <expression'>
         epsilon
20-3<expression''> : ( < liste-expressions> ) < expression'>
         | <variable'> <expression'>
20-4<expression'''> : <binary-op'> <expression> <expression'>
        epsilon
21-1 < liste-expressions > : < expression > < liste-expressions '>
epsilon
21-2 < liste-expressions'>: ,<expression>liste-expressions'>
epsilon
22-1 < condition > : ! ( < condition > ) < condition '>
                 ( <condition> ) <condition'>
                 <expression > <binary-comp> <expression >
    <condition'>
22-2 < condition'> : < binary-rel> < condition> < condition'>
         epsilon
23-1 < binary - op > : + | - | * | / | << | >> | & | | |
23-2 < binary - op' > : + | -
24 - \langle \text{binary-rel} \rangle : \&\& | | |
25- <br/> <br/> comp> : < | > | >= | <= | !=
<lire> : lire (<liste-declarateur>);
<ecrire> : ecrire (<liste-declarateur>);
<chaine>: "<DefChaine>"
<DefChaine>: <lettre> <DefChaine>
         <chiffre> < DefChaine>
         epsilon
```

```
<entier >: < chiffre >< entier > | epsilon 
<mot>: <letter > <mot> | epsilon 
< chiffre >: 0|1|2|3|4|5|6|7|8|9
```

2.7 Exemples d'erreurs levées par le syntaxique:

```
1 int a1;
2 int a2;
3
4 chaine a22
5 extern void produit(int x,int y);
```

Figure 2.7: Texte source.

```
Erreur : ';' attendu ! Ligne : 5
==> Le code est syntaxiquement faux.
```

Figure 2.8: Erreur : oublie du point virgule.

```
1 int a1;
2 int a2;
3 int a3[23];
4
```

Figure 2.9: Texte source.

```
Erreur : ']' attendu ! Ligne : 3
==> Le code est syntaxiquement faux.
```

Figure 2.10: Erreur : oublie de fermer un crochet ouvrant.

```
1 int a3[23];
2
3 chaine a22;
4
5 a3[3] = 7;
```

Figure 2.11: Texte source.

```
Erreur : int, chaine, void, extern attendu ! Ligne : 5
==> Le code est syntaxiquement faux.
```

Figure 2.12: Erreur : opération non permise.

```
int a3[23];

chaine a22;
extern void produit(int x,int y);
extern add(int x,int y);
```

Figure 2.13: Texte source.

```
Erreur : int, chaine, void attendu ! Ligne : 6
==> Le code est syntaxiquement faux.
```

Figure 2.14: Erreur : oublie de donner un type lors de la déclaration d'une fonction.

```
int a3[23];
chaine a22;

extern void (int x,int y);
extern int add(int x,int y);
```

Figure 2.15: Texte source.

```
Erreur : ID attendu ! Ligne : 6
==> Le code est syntaxiquement faux.
```

Figure 2.16: Erreur : oublie de l'identifiant.

Chapter 3

Partie Sémantique

3.1 Introduction

La partie sémantique est la partie du compilateur qui s'occupe des vérifications liés à l'execution du programme. La phase d'analyse sémantique rassemble des informations qui serviront dans la production de code et contrôle un certain nombre de coherences s'emantiques. Par exemple, c'est au cours de cette phase que sont déterminés les instructions, les expressions et les identificateurs. Sont également contrôlés les type dans les affectations et les passages de paramètres. Les types d'indices utilisés pour les tableaux peuvent aussi être vérifiés.

3.2 La grammaire du langage avec des actions sémantiques

```
1-1 programme> : int programme'>
                    | chaine cprogramme'>
                     | void identificateur {verifierRedefinition}(<liste-parms> ) {
   <liste-declarations> <liste-instructions> }                                                                                                                                                                                                                                                                                                                                             
                    | extern <type> identificateur {verifierRedefinition} ((extern <type>);
   cprogramme>
                    epsilon
1-2 rogramme'> : identificateur {verifierRedefinition} rogramme">
5-1 < Declarateur>: identificateuur {verifierRedefinition} < Declarateur'>
10-  : int identificateur {verifierRedefinition} | chaine identificateur {verifierRedefinition}
12-1 < liste-instructions > : < iteration > < liste-instructions >
   |<selection> <liste-instructions>
    <saut> te-instructions>
   | identificateur{estDefini} <aff-app>;<liste-instructions>
    <blood>te-instructions>
   epsilon
```

Figure 3.1: Grammaire avec actions sémantiques.

```
12-2 <aff-app>:{checkType} <variable'>=<expression>
|(liste-expressions>)

19-1 <variable> : identificateur {estDefini} <variable'>
19-2 <variable'> : [{estTable} <expression> ] | epsilon

20-1 <expression> : (<expression>) <expression'>
| - <expression> <expression'>
| identificateur {estDefini} <expression'>
| <chaine> <expression''>
| constante <expression'>
| epsilon
```

Figure 3.2: Grammaire avec actions sémantiques

3.3 Définition des actions sémantiques

3.3.1 Vérification des redéfinitions

L'action **vérifierRedéfinition** vérifie si la déclaration d'une certaine variable a été déja faite dans le même contexte ou dans un contexte supérieur. Son prototype :

```
bool verifier Redefinition (unite u, int ligne, bool emplacement, int contexte, int fonction);
```

- AnalyseLexical::unite u : la structure utilisée dans la partie léxicales pour stocker les unités léxicales et les attributs correspondants. Son utilisation se fait dans la partie syntaxique où on passe le 'motCourant', qui est une unité, en paramètes à cette fonction pour l'analyse sémantique;
- int ligne : c'est la ligne où on se trouve.
- bool emplacement : si on vient d'une importation de fonction avec le mot clé externe; cette booléen prend la valeur "vraie" pour ne pas compter les variables introduites dans le prototype de la fonction comme variables du programme;
- int contexte : c'est le contexte où on se trouve. Soit on est au contexte global (=0); Soit on est à l'intérieur d'une fonction (=1);
- int fonction: contient le nombre 0 si on est dans un contexte global, sinon, cette variable prend comme valeur l'ordre de définition de la fonction.

L'appel de cette fonction avant chaque declaration nous permet de vérifier dans la table des symboles utilisées si on est passé par cette variable deux fois, la première c'est la déclaration de la variable et la deuxième c'est la redéclaration.

3.3.2 Vérification des définitions

L'action **estDéfini** permet de vérifier si une variable ou une fonction a été declarée avec qu'elle soit utilisée. Son prototype:

```
bool AnalyseSemantique::estDefini(unite u, int contexte, int ligne, int fonction)
```

Son utilisation est similaire à celle de la vérification des redéfinitions. Son appel se fait après chaque identificateur qui introduit une manipulation de la variable et pas sa déclaration. Donc, elle vérifie dans la table des symboles si on a déja défini cette

variable dans le même contexte ou dans un contexte supérieur et avant la ligne où elle est utilisée.

3.3.3 Vérification du caractère simple ou composé d'une variable

L'action **estTable** vérifie si la variable, sur laquelle on utilise les crochets, et un tableau ou non. Son prototype et ses paramètes sont similaires aux vérifications présentées et on l'utilise lorsqu'on utilise les crochets sur une variable dans une phase de manipulation différente de la déclaration.

3.3.4 Vérification des types

L'action **CheckType** vérifie si le type manipulé correspond aux opérations qu'on lui effectue. Par exemple, l'affectation d'une chaine de caractères à un "int". Cette fonction vérifie aussi si la variable manipulée est un tableau, et oblige de spécifier l'index où on veut affecter la valeur manipulée. Son prototype:

```
bool AnalyseSemantique::checkTyp[U(+FFFD] unite a, unite b, unite c, int nbCrochets, int ligne, int contexte, int fonction)
```

- Les trois unités passées en parametres contienent les unités correspondantes à une opération "a = b + c" ou "a = b" avec "c" nulle.
- Le nombre de crochets correspond au nombre de crochets utilisés dans l'opération pour savoir si les variables qu'on manipule sont des tableas et une spécification de l'index concerné est obligée.

3.3.5 Vérifications des index nulles

Cette fonctionalité a été ajoutée lors du parcours du code à traduire par le sémantique. s'il tombe sur une taille de tableau négative, il la signale.

chaine testc[-3];

Figure 3.3: Erreur index négative.

Tableau de taille negative, Ligne : 25

Figure 3.4: Erreur index négative.

3.3.6 Vérification des manipulations de chaines

Dans la partie syntaxique, on a donné au type chaine que deux opérations binaires valables "+" et "-". Si on essaie de faire d'autres opérations, le syntaxique lève une erreur de syntaxe. Mais cela n'est pas valable dans les deux sens: "chaine" * 3 va être signalée, mais 3 * "chaine" ne va pas l'être. Donc cela doit être implémenté dans cette partie et l'action de vérification des types le couvre.

3.4 Structures utilisées

3.4.1 Table des symboles

Pour implémenter ces fonctionalités, on utilise une table de symboles qui se remplis avant l'exécution du syntaxique

```
vector < variable *> idents;
```

C'est un vecteur de pointeurs 'variable', une structure qui sera présentée par la suite.

3.4.2 La structure variable

C'est une structure qui contient les données prises par le parcours fait par la fonction ajouterIdentifiants() du sémantique qui fait un parcours du code et ajoute tous les identifiants, des variables et fonctions etc, dans cette table pour être expoloitée par les actions sémantiques par la suite. Sa définition:

```
struct variable {
    string ident; // Va contenir l'identifiant de la
        variable courante
    string type=""; // Va contenir le type des
        identifiants
    int scope =0; // Variables globales, locales .... par
        niveau (0 = globale)
    int taille = 0; // s'il s'agit d'un tableau
    int times = 0; // nombre de fois on est passe par cet
        identifiant
    int ou = 0; // Dans quelle ligne la definition de la
        variable a ete rencontree
    int function = 0; // la fonction ou se trouve la
        declaration de la variable.
};
```

3.5 Exemples d'erreurs levées par le sémantique.

```
1 int a1;
2 int a2;
3 int a3[23];
4 int a1;
```

Figure 3.5: Erreur de redéfinition.

```
Redefinition de : a1 , ligne : 4
===> Le code est semantiquement faux ...
```

Figure 3.6: Erreur de redéfinition.

```
24  int s;
25  chaine testc;
26
27  s = testc;
```

Figure 3.7: Erreur des types lors d'une affectation.

Incoherence des types manipules... Ligne : 27

Figure 3.8: Erreur des types lors d'une affectation.

```
25    int s;
26
27    s = "ch";
```

Figure 3.9: Erreur des types lors d'une affectation.

```
Pas de conversion connue entre le type entier et les chaines ... Ligne : 28
```

Figure 3.10: Erreur des types lors d'une affectation.

```
chaine testc;
testc = 33;
```

Figure 3.11: Erreur des types lors d'une affectation.

```
Pas de conversion connue entre le type entier et les chaines ... Ligne : 28
```

Figure 3.12: Erreur des types lors d'une affectation.

```
25    chaine testc[3];
26
27    testc = "ch";
```

Figure 3.13: Erreur d'indice d'un tableau.

```
/eillez specifier l'index ou vous voulez stocker... Ligne : 27
```

Figure 3.14: Erreur d'indice d'un tableau.

```
int var1;
var1 = var2 +3;
```

Figure 3.15: Erreur de définition.

```
var2 doit etre defini avant d'etre utilisee... Ligne 28
```

Figure 3.16: Erreur de définition.